

Makine Öğrenmesi Destekli Çalışan Churn Tahmin Sistemi: PostgreSQL Tabanlı Veritabanı Tasarımı ve XGBoost ile SHAP Açıklanabilirliği

Mert Yasin YILMAZ

Bilgisayar Mühendisliği Bölümü

Kastamonu Üniversitesi, Kastamonu, Türkiye

Özet

Bu çalışmada, kurumsal çalışan ayrılma (churn) riskini tahmin etmek amacıyla geliştirilmiş uçtan uca bir veritabanı destekli makine öğrenmesi sistemi sunulmaktadır. PostgreSQL 16 üzerine kurulu, üçüncü normal form (3NF) uyumlu sekiz tabloluk şema; görünüm (view), tetikleyiciler (trigger), saklı yordamlar (stored procedure) ve rol tabanlı erişim denetimi gibi gelişmiş veritabanı özelliklerini kapsamaktadır. IBM HR Analytics veri kümesinden (1.470 kayıt) beslenen XGBoost modeli %87,4 doğruluk ve 0,91 ROC-AUC skoruna ulaşmış; SHAP açıklanabilirlik katmanı bireysel tahmin gerekçelerini görselleştirmektedir. FastAPI tabanlı RESTful arka uç, JWT kimlik doğrulama ve üç kademeli yetkilendirme (Admin/HR/Manager) sunarken React 18 ile geliştirilen ön yüz gerçek zamanlı KPI panoları, departman bazlı ısı haritaları ve SHAP şelale grafikleri içermektedir. Audit log tetikleyicileri, n8n iş akışı otomasyonu ve Excel dışı aktarma özellikleri sisteme kurumsal olgunluk kazandırmaktadır.

Anahtar Kelimeler—Churn Tahmini, PostgreSQL, XGBoost, SHAP, FastAPI, React, Veritabanı Yönetimi, Makine Öğrenmesi, JWT, REST API

I. Giriş

İnsan kaynakları yönetiminde çalışan devir hızı, işe alım maliyetleri ve kurumsal bilgi birikiminin yitirilmesi açısından kritik bir sorun oluşturmaktadır. Literatüre göre bir çalışanın işten ayrılması; yıllık maaşının %50 ile %200'ü arasında ek maliyet doğurmaktadır [1]. Yalnızca doğrudan işe alım ve eğitim giderleri değil; kaybedilen kurumsal bilgi birikimi, ekip motivasyonundaki düşüş ve müşteri ilişkilerinin sekteye uğraması da bu maliyetin önemli bileşenlerini oluşturmaktadır. Bu olgusal gerçeklik, ayrılma riskini proaktif biçimde tahmin edebilen ve insan kaynakları ekiplerini önceden uyarabilen akıllı sistemlere duyulan ihtiyacı doğurmaktadır.

Son yıllarda dijital dönüşümün hız kazanmasıyla birlikte kurumsal İK süreçleri de veri odaklı bir yapıya bürünmektedir. Büyük veri altyapıları ve makine öğrenmesi modelleri, çalışan davranışlarındaki örüntüleri geçmiş verilerden öğrenerek gelecekteki ayrılma olasılıklarını tahmin etme kapasitesi sunmaktadır. Ancak bu alandaki pek çok çalışma, tahmin modelini ön plana çıkarırken modelin beslendiği veritabanı katmanını ikincil planda bırakmaktadır. Sağlam bir veri altyapısı

olmaksızın modelin doğruluğunu korumak ve tahminlerin denetlenebilirliğini sağlamak güçleşmektedir.

Bu çalışma, Veri Tabanı Yönetim Sistemleri dersinin final ödevi kapsamında geliştirilmiş; çalışan churn tahminine yönelik bütünlük bir sistem mimarisini ortaya koymaktadır. Projenin odak noktası, sağlam bir veritabanı tasarımının makine öğrenmesi bileşenleriyle kusursuz entegrasyonudur. PostgreSQL 16'nın gelişmiş özellikleri — JSONB sütunları, tetikleyiciler ve saklı yordamlar— model çıktılarını depolamak ve eksiksiz bir denetim izi oluşturmak için merkezi işlev üstlenmektedir.

Çalışmanın başlıca katkıları: (1) 3NF uyumlu sekiz tabloluk ilişkisel şema, (2) tetikleyici tabanlı otomatik denetim günlüğü, (3) XGBoost ve SHAP entegrasyonu, (4) JWT ile üç kademeli rol erişim denetimi, (5) n8n otomasyon bildirimleri, (6) React 18 gerçek zamanlı yönetim panosudur.

II. İLGİLİ ÇALIŞMALAR

Çalışan devir hızı tahmini, makine öğrenmesi literatüründe kapsamlı biçimde incelenmiştir. Saradhi ve Palshikar [2], destek vektör makineleri ve karar ağaçlarını karşılaştırarak devamsızlık ve iş doyumu verilerinin churn tahmininde belirleyici rol oynadığını göstermiştir. Fallucchi vd. [3] ise IBM HR Analytics veri kümesini lojistik regresyon, rastgele orman ve XGBoost ile analiz etmiş; XGBoost'un en yüksek F1 skoruna ulaştığını saptamıştır.

Son dönemde açıklanabilir yapay zeka (XAI) yaklaşımları bu alanda yaygınlaşmaktadır. Lundberg ve Lee [4] tarafından geliştirilen SHAP (SHapley Additive exPlanations) çerçevesi, karmaşık modellerin özellik katkılarını Shapley değerleriyle niceleyen ve insan kaynakları ekiplerine eyleme dönüştürülebilir içgörüler sunan bir araç olarak öne çıkmaktadır. Bu çalışma, SHAP'ı bireysel çalışan düzeyinde risk gerekçelendirmesi için veritabanı katmanıyla entegre eden ender uygulamalardan birini temsil etmektedir.

Veritabanı perspektifinden değerlendirildiğinde, mevcut çalışmaların büyük bölümünün veri depolama katmanını ikincil planda bıraktığı görülmektedir. Bu çalışma, PostgreSQL'in gelişmiş özelliklerini —JSONB indeksler, tetikleyici tabanlı denetim günlüğü, görünümüler— ön plana çıkararak ilgili boşluğu doldurmayı hedeflemektedir.

III. SİSTEM MİMARİSİ

Sistem dört katmanlı bir mimari üzerine inşa edilmiştir: (1) PostgreSQL 16 veri katmanı, (2) Python 3.12 + FastAPI + SQLAlchemy 2.0 ile oluşturulan arka uç hizmet katmanı, (3) scikit-learn ve XGBoost ile geliştirilen makine öğrenmesi katmanı, (4) React 18 + Vite + TailwindCSS + shadcn/ui tabanlı ön yüz katmanı. Tüm servisler tek bir START_ALL.bat betiğiyle başlatılmakta; n8n iş akışı motoru ise zamanlı toplu tahmin ve e-posta bildirimlerini otomatikleştirmektedir.

A. Teknoloji Yığını

TABLO I. Teknoloji Yığını

Katman	Teknoloji	Sürüm
Veritabanı	PostgreSQL	16
Arka Uç	FastAPI + SQLAlchemy	0.115 / 2.0
ML	XGBoost + SHAP	2.1 / 0.46
Ön Yüz	React + Vite	18 / 5
Kimlik Doğrulama	python-jose + bcrypt	3.3 / 4.2
Otomasyon	n8n	1.x

B. Veri Akışı

Ham IBM HR Analytics CSV dosyası (1.470 satır, 35 özellik), seed_db.py betiğiyle PostgreSQL tablolarına yüklenmektedir. ML pipeline'ı bu tablolardan veri çekerek özellik mühendisliği uygular, modeli eğitir ve model_registry tablosuna yeni versiyon kaydeder. FastAPI /api/predictions uç noktası, eğitilmiş modeli bellekten yükleyerek çevrimiçi tahmin hizmeti sunar.

IV. VERİTABANI TASARIMI

Veritabanı şeması, veri tekrarını ve güncelleme anomalilerini önlemek amacıyla üçüncü normal forma (3NF) göre tasarlanmıştır. Her tablo, yalnızca birincil anahtara bağımlı sütunlar içermekte; geçişli bağımlılıklara izin verilmemektedir.

V. MAKİNE ÖĞRENMESİ PIPELINE'I

A. Tablo Şeması

TABLO II. Veritabanı Şeması

Tablo	Amaç	Öne Çıkan Özellik
departments	Departman ana tablosu	manager_id FK
job_roles	Pozisyon kataloğu	UNIQUE(name)
employees	Çalışan ana kaydı	35 özellik, 3NF
employee_metrics	Performans geçmişi	Zaman serisi
predictions	ML çıktıları	SHAP JSONB, GIN indeks
users	Sistem kullanıcıları	Rol tabanlı erişim
audit_log	Denetim günlüğü	Trigger otomatik doldurur
model_registry	Model versiyonları	Metrik JSONB

B. Gelişmiş Veritabanı Özellikleri

Sistem, DBMS dersinin gerektirdiği ileri düzey veritabanı özelliklerini eksiksiz biçimde uygulamaktadır. `v_high_risk_employees`, `v_department_attrition_rate` ve `v_monthly_predictions` görünümleri sık kullanılan sorguları kapsüllemektedir. `sp_recalculate_risk(employee_id)` saklı yordamı, bir çalışanın metriği güncellendiğinde tahmin skorunu otomatik olarak yeniden hesaplar.

`trg_audit_employees` tetikleyicisi, `employees` tablosundaki her `INSERT/UPDATE/DELETE` işlemini `audit_log` tablosuna JSONB formatında kaydeder. `current_setting('app.current_user')` fonksiyonu aracılığıyla işlemi yapan kullanıcı bilgisi yakalanmakta; böylece tam izlenebilirlik sağlanmaktadır. B-tree indeksler (`department_id`, `job_role_id`) sorgu performansını artırırken GIN indeks, `predictions.shap_values` JSONB sütununda hızlı arama yapılmasına olanak tanımaktadır.

A. Veri Ön İşleme

35 ham özellikten 28 tanesi modele dahil edilmiştir. Kategorik değişkenler (`BusinessTravel`, `Department`, `EducationField`, `Gender`, `JobRole`, `MaritalStatus`, `OverTime`) one-hot kodlama ile sayısallaştırılmıştır. Sürekli değişkenler `StandardScaler` ile $[0,1]$ aralığına ölçeklendirilmiştir. Hedef değişken dengesizliğini gidermek için SMOTE uygulanmış; eğitim/test ayrımı %80/%20 olarak belirlenmiştir.

B. Model Seçimi ve Değerlendirme

Üç model karşılaştırmalı olarak değerlendirilmiştir: Lojistik Regresyon, Rastgele Orman ve XGBoost. 5 katlı çapraz doğrulama ve `GridSearchCV` hiperparametre optimizasyonu sonucunda XGBoost en yüksek ROC-AUC değerini elde etmiş ve üretim modeli olarak seçilmiştir.

TABLO III. Model Karşılaştırma Sonuçları

Model	Doğruluk	F1	ROC-AUC	Recall
Lojistik Regresyon	%79,3	%74,1	0,83	%71,2
Rastgele Orman	%84,6	%80,8	0,88	%78,5
XGBoost (seçilen)	%87,4	%84,2	0,91	%83,7

C. SHAP Açıklanabilirliği

Her tahmin için SHAP değerleri hesaplanmakta ve `predictions.shap_values` JSONB sütununa yazılmaktadır. Şelale (waterfall) grafikleri, tek bir çalışan için hangi faktörlerin churn riskini artırıp azalttığını görselleştirmektedir. Analiz sonuçlarına göre `OverTime`, `MonthlyIncome`, `JobSatisfaction` ve `YearsAtCompany` en belirleyici özellikler olarak öne çıkmaktadır.

VI. RESTFUL API KATMANI

FastAPI çerçevesi, OpenAPI 3.0 uyumlu otomatik dökümantasyon üreten /docs uç noktasıyla birlikte gelmektedir. Uygulama dört router modülüne ayrılmıştır: auth (JWT kimlik doğrulama), employees (CRUD + filtreleme), predictions (tek çalışan ve toplu tahmin) ve admin (model yönetimi, kullanıcı yönetimi, denetim günlüğü).

A. Kimlik Doğrulama ve Yetkilendirme

POST /api/auth/login uç noktası, kullanıcı adı/şifre doğrulamasının ardından 30 dakika geçerli JWT erişim tokeni döndürmektedir. Her korumalı uç noktada require_role() bağımlılık enjeksiyonu çalışmakta; Admin tüm kaynaklara erişebilirken Manager yalnızca kendi departmanının verilerini görmektedir.

B. Temel Uç Noktalar

TABLO IV. Temel API Uç Noktaları

Uç Nokta	Metot	Açıklama
/api/auth/login	POST	JWT tokeni al
/api/employees	GET	Filtreli çalışan listesi
/api/employees/{id}	GET/PUT/DELETE	Çalışan CRUD
/api/predictions/{id}	GET	SHAP'lı tahmin sonucu
/api/predictions/batch	POST	Toplu tahmin
/api/admin/retrain	POST	Modeli yeniden eğit
/api/admin/audit-log	GET	Denetim günlüğü

VII. KULLANICI ARAYÜZÜ

Ön yüz, React 18 + Vite ile geliştirilmiş; TailwindCSS ve shadcn/ui bileşen kütüphanesi kullanılmıştır. TanStack Query asenkron veri yönetimini ve optimistik UI güncellemelerini üstlenirken Recharts kütüphanesi grafikleri render etmektedir.

A. Sayfa Yapısı

Sekiz sayfadan oluşan tek sayfa uygulaması (SPA) şu modülleri kapsar: (1) Giriş sayfası; (2) Ana pano —KPI kartları, departman ısı haritası; (3) Çalışanlar listesi — filtreleme, arama, risk renk kodlaması; (4) Çalışan detayı —profil, SHAP şelale grafiği; (5) Tahmin formu; (6) Model yönetimi; (7) Denetim günlüğü; (8) Kullanıcı yönetimi.

B. What-If Analizi

Çalışan detay sayfasındaki 'Senaryo Simülasyonu' bölümü, İK uzmanlarının maaş, mesai ve iş doyumu gibi parametreleri kaydırıcılarla değiştirerek churn riskine etkisini gerçek zamanlı görmesini sağlamaktadır.

VIII. DENEYSEL DEĞERLENDİRME

IBM HR Analytics veri kümesi 1.470 çalışan kaydı ve 35 özellikten oluşmaktadır. Doğal dengesizlik (churn oranı ~%16) SMOTE ile giderilmiştir. XGBoost, 5 katlı çapraz doğrulamada ortalama $0,91 \pm 0,02$ ROC-AUC elde etmiştir. Ayrılan çalışanların %83,7'si doğru tahmin edilmiş (recall); yanlış pozitif oranı %11,3 kalmıştır.

API yanıt süreleri 100 eşzamanlı istek altında ölçülmüştür: /employees listesi ortalama 48 ms, tek tahmin 120 ms, toplu tahmin (100 çalışan) 890 ms. PostgreSQL GIN indeksi, SHAP JSONB sorgusunu indeksli duruma göre 12 kat hızlandırmıştır.

IX. TARTIŞMA

Geliştirilen sistem, veritabanı ağırlıklı tasarımı makine öğrenmesi ile başarıyla bütünleştirmektedir. Tetikleyici tabanlı denetim günlüğü mekanizması GDPR ve benzeri uyumluluk gereksinimlerini karşılamaktadır. Rol tabanlı erişim denetimi, büyük ölçekli kurumsal dağıtımlar için gerekli güvenlik katmanını sağlamaktadır.

Sistemin başlıca sınırlılıkları: mevcut veri kümesinin yalnızca 1.470 kayıttan oluşması; statik model altyapısının kullanılması (concept drift tespiti planlanmaktadır). Gelecek çalışmada derin öğrenme modelleri ve yapılandırılmamış metin verisi denenecektir.

X. SONUÇ

BU ÇALIŞMADA POSTGRESQL 16'NİN GELİŞMİŞ ÖZELLİKLERİNİ, XGBOOST MODELİNİ VE SHAP AÇIKLANABİLİRLİK KATMANINI BİR ARAYA GETİREN KAPSAMLI BİR ÇALIŞAN CHURN TAHMİN SİSTEMİ GELİŞTİRİLMİŞTİR. SEKİZ TABLOLUK 3NF ŞEMA, TETİKLEYİCİ TABANLI DENETİM GÜNLÜĞÜ, GÖRÜNÜMLER VE SAKLI YORDAMLAR SİSTEMİN DBMS OLGUNLUĞUNU ORTAYA KOYMAKTADIR.

DENEYSEL SONUÇLAR, XGBOOST MODELİNİN %87,4 DOĞRULUK VE 0,91 ROC-AUC İLE GÜÇLÜ SINIFLANDIRMA PERFORMANSI SERGİLEDİĞİNİ KANITLAMAKTADIR. SHAP ENTEGRASYONU MODELİN ŞEFFAFLIĞINI ARTIRARAK İK EKİPLERİNİN TAHMİN GEREKÇELERİNİ ANLAYIP HAREKETE GEÇMESİNİ KOLAYLAŞTIRMAKTADIR. SİSTEM GERÇEK KURUMSAL ORTAMDA KULLANIMA HAZIR OLGUNLUĞA ULAŞMIŞTIR.

REFERANSLAR

- [1] W. F. CASCIO, "MANAGING HUMAN RESOURCES," 10TH ED., MCGRAW-HILL EDUCATION, NEW YORK, 2018.
- [2] V. V. SARADHI VE G. K. PALSHIKAR, "EMPLOYEE CHURN PREDICTION," EXPERT SYSTEMS WITH APPLICATIONS, CİLT 38, SAYI 3, SS. 1999-2006, 2011.
- [3] F. FALLUCCHI, M. COLADANGELO, R. GIULIANO VE E. DE LUCA, "PREDICTING EMPLOYEE ATTRITION USING MACHINE LEARNING TECHNIQUES," COMPUTERS, CİLT 9, SAYI 4, S. 86, 2020.
- [4] S. M. LUNDBERG VE S.-I. LEE, "A UNIFIED APPROACH TO INTERPRETING MODEL PREDICTIONS," ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, CİLT 30, 2017
- [5] T. CHEN VE C. GUESTRIN, "XGBOOST: A SCALABLE TREE BOOSTING SYSTEM," PROC. 22ND ACM SIGKDD, SS. 785-794, 2016.
- [6] S. CHAWLA, K. BOWYER, L. HALL VE W. KEGELMEYER, "SMOTE: SYNTHETIC MINORITY OVER-SAMPLING TECHNIQUE," JOURNAL OF AI RESEARCH, CİLT 16, SS. 321-357, 2002.
- [7] IBM, "IBM HR ANALYTICS EMPLOYEE ATTRITION & PERFORMANCE," KAGGLE, 2017. [CEVRİMİCİ].
ERİSİM:
[HTTPS://WWW.KAGGLE.COM/DATASETS/PAVANSUBHASH
T/IBM-HR-ANALYTICS-ATTRITION-DATASET](https://www.kaggle.com/datasets/pavansubhast/ibm-hr-analytics-attrition-dataset)
- [8] S. RAMESH, "FASTAPI: MODERN, FAST WEB FRAMEWORK FOR BUILDING APIS WITH PYTHON," PACKT PUBLISHING, 2023.

Machine Learning-Based Employee Churn Prediction System: PostgreSQL-Driven Database Design with XGBoost and SHAP Explainability

Mert Yasin YILMAZ

*Department of Computer Engineering
Kastamonu University, Kastamonu, Turkey*

Abstract

This study presents an end-to-end database-backed machine learning system designed to predict employee churn risk within organizations. The schema, built on PostgreSQL 16 and normalized to third normal form (3NF) across eight tables, incorporates advanced database features including views, triggers, stored procedures, and role-based access control. An XGBoost model trained on the IBM HR Analytics dataset (1,470 records) achieved 87.4% accuracy and a 0.91 ROC-AUC score; a SHAP explainability layer visualizes the reasoning behind individual predictions. The FastAPI-based RESTful back end provides JWT authentication and three-tier authorization (Admin/HR/Manager), while the React 18 front end delivers real-time KPI dashboards, department-level heat maps, and SHAP waterfall charts. Audit-log triggers, n8n workflow automation, and Excel export functionality bring enterprise-grade maturity to the system.

Index Terms—Churn Prediction, PostgreSQL, XGBoost, SHAP, FastAPI, React, Database Management, Machine Learning, JWT, REST API

I. INTRODUCTION

Employee turnover is a critical problem in human resources management, generating significant costs in recruitment expenses and the loss of institutional knowledge. According to the literature, an employee's departure generates additional costs ranging from 50% to 200% of their annual salary [1]. Not only direct recruitment and training expenses, but also the loss of organizational knowledge, decline in team motivation, and disruption of customer relations constitute important components of this cost. This factual reality creates the need for intelligent systems that can proactively predict departure risk and alert human resources teams in advance.

With the acceleration of digital transformation in recent years, corporate HR processes are also taking on a data-driven structure. Big data infrastructures and machine learning models offer the capacity to predict future departure probabilities by learning patterns in employee behavior from historical data. However, many studies in this field relegate the database layer to a secondary position while emphasizing the prediction

model. Without a solid data infrastructure, maintaining model accuracy and ensuring auditability of predictions becomes difficult.

This study was developed as the final project for the Database Management Systems course and presents an integrated system architecture for employee churn prediction. The focus is the seamless integration of robust database design with machine learning components. PostgreSQL 16's advanced features—JSONB columns, triggers, and stored procedures—serve a central function for storing model outputs and creating a complete audit trail. The RESTful layer built with FastAPI connects the database to the application layer, while the React 18 front end presents data to HR specialists in an understandable manner.

The main contributions of this study are: (1) a relational schema of eight tables compliant with 3NF, (2) trigger-based automatic audit logging, (3) XGBoost and SHAP integration, (4) three-tier role-based access control with JWT, (5) n8n automation notifications, and (6) React 18 real-time management dashboard.

II. RELATED WORK

Employee turnover prediction has been extensively studied in the machine learning literature. Saradhi and Palshikar [2] compared support vector machines and decision trees, demonstrating that absenteeism and job satisfaction data play a decisive role in churn prediction. Fallucchi et al. [3] analyzed the IBM HR Analytics dataset with logistic regression, random forest, and XGBoost, finding that XGBoost achieved the highest F1 score.

In recent years, explainable artificial intelligence (XAI) approaches have become widespread in this field. The SHAP (SHapley Additive exPlanations) framework developed by Lundberg and Lee [4] quantifies feature contributions of complex models with Shapley values and provides actionable insights to HR teams. This study represents one of the rare implementations that integrates SHAP with the database layer for individual employee-level risk justification.

From a database perspective, the majority of existing studies relegate the data storage layer to a secondary position. This study aims to fill the relevant gap by highlighting PostgreSQL's advanced features—JSONB indexes, trigger-based audit logging, and views.

III. SYSTEM ARCHITECTURE

The system is built on a four-layer architecture: (1) PostgreSQL 16 data layer, (2) backend service layer created with Python 3.12 + FastAPI + SQLAlchemy 2.0, (3) machine learning layer developed with scikit-learn and XGBoost, (4) front end layer based on React 18 + Vite + TailwindCSS + shadcn/ui. All services are started with a single START_ALL.bat script; the n8n workflow engine automates scheduled batch predictions and email notifications.

A. Technology Stack

TABLE I. Technology Stack

Layer	Technology	Version
Database	PostgreSQL	16
Back End	FastAPI + SQLAlchemy	0.115 / 2.0
ML	XGBoost + SHAP	2.1 / 0.46
Front End	React + Vite	18 / 5
Authentication	python-jose + bcrypt	3.3 / 4.2
Automation	n8n	1.x

B. Data Flow

The raw IBM HR Analytics CSV file (1,470 rows, 35 features) is loaded into PostgreSQL tables via the seed_db.py script. The ML pipeline fetches data from these tables, applies feature engineering, trains the model, and registers a new version in the model_registry table. The FastAPI /api/predictions endpoint loads the trained model from memory and provides online prediction service.

IV. DATABASE DESIGN

The database schema was designed according to third normal form (3NF) to prevent data redundancy and update anomalies. Each table contains only columns dependent on the primary key; transitive dependencies are not permitted.

A. Table Schema

TABLE II. Database Schema

Table	Purpose	Key Feature
departments	Department master	manager_id FK
job_roles	Position catalog	UNIQUE(name)
employees	Employee master record	35 features, 3NF
employee_metrics	Performance history	Time series
predictions	ML outputs	SHAP JSONB, GIN index
users	System users	Role-based access
audit_log	Audit trail	Trigger auto-fills
model_registry	Model versions	Metrics JSONB

B. Advanced Database Features

The system fully implements the advanced database features required by the DBMS course. The `v_high_risk_employees`, `v_department_attrition_rate`, and `v_monthly_predictions` views encapsulate frequently used queries. The `sp_recalculate_risk(employee_id)` stored procedure automatically recalculates the prediction score when an employee's metric is updated.

The `trg_audit_employees` trigger records every INSERT/UPDATE/DELETE operation on the `employees` table in JSONB format to the `audit_log` table. User information is captured via `current_setting('app.current_user')`, providing full traceability. B-tree indexes (`department_id`, `job_role_id`) improve query performance, while the GIN index enables fast searching in the `predictions.shap_values` JSONB column.

V. MACHINE LEARNING PIPELINE

A. Data Preprocessing

28 of the 35 raw features were included in the model. Categorical variables (BusinessTravel, Department, EducationField, Gender, JobRole, MaritalStatus, OverTime)

were numerized with one-hot encoding. Continuous variables were scaled to the [0,1] range with StandardScaler. SMOTE was applied to address target variable imbalance; the training/test split was set at 80%/20%.

B. Model Selection and Evaluation

Three models were comparatively evaluated: Logistic Regression, Random Forest, and XGBoost. Following 5-fold cross-validation and GridSearchCV hyperparameter optimization, XGBoost achieved the highest ROC-AUC value and was selected as the production model.

TABLE III. Model Comparison Results

Model	Accuracy	F1	ROC-AUC	Recall
Logistic Regression	79.3%	74.1%	0.83	71.2%
Random Forest	84.6%	80.8%	0.88	78.5%
XGBoost (selected)	87.4%	84.2%	0.91	83.7%

C. SHAP Explainability

SHAP values are calculated for each prediction and written to the `predictions.shap_values` JSONB column. Waterfall charts ranking feature contributions visualize which factors increase and decrease churn risk for a single employee. According to the analysis results, OverTime, MonthlyIncome, JobSatisfaction, and YearsAtCompany emerge as the most decisive features.

VI. RESTFUL API LAYER

The FastAPI framework comes with a `/docs` endpoint that produces OpenAPI 3.0-compliant automatic documentation. The application is divided into four router modules: `auth` (JWT authentication), `employees` (CRUD + filtering), `predictions` (single employee and batch prediction), and `admin` (model management, user management, audit log).

A. Authentication and Authorization

The POST /api/auth/login endpoint returns a JWT access token valid for 30 minutes after username/password verification. The require_role() dependency injection runs on every protected endpoint; Admin can access all resources while Manager can only view their own department's data. Row-level security is applied at the SQLAlchemy filter layer rather than PostgreSQL policies.

B. Key Endpoints

TABLE IV. Key API Endpoints

Endpoint	Method	Description
/api/auth/login	POST	Obtain JWT token
/api/employees	GET	Filtered employee list
/api/employees/{id}	GET/PUT/DELETE	Employee CRUD
/api/predictions/{id}	GET	Prediction with SHAP
/api/predictions/batch	POST	Batch prediction
/api/admin/retrain	POST	Retrain model
/api/admin/audit-log	GET	Audit log

VII. USER INTERFACE

The front end was developed with React 18 + Vite and uses the TailwindCSS and shadcn/ui component library. TanStack Query handles asynchronous data management and optimistic UI updates, while the Recharts library renders bar, line, pie, and heat map charts.

A. Page Structure

The eight-page single page application (SPA) includes: (1) Login page—JWT authentication, role selection; (2) Main dashboard—KPI cards, department heat map, monthly trend; (3) Employee list—filtering, search, risk color coding; (4) Employee detail—profile, SHAP waterfall chart; (5) Prediction form—instant score; (6) Model management—model versions and retraining

for Admin; (7) Audit log—trigger records; (8) User management—CRUD and role assignment.

B. What-If Analysis

The 'Scenario Simulation' section on the employee detail page enables HR specialists to change parameters such as salary, overtime, and job satisfaction with sliders and receive real-time answers to the question 'What would churn risk be if I increase salary by 10%?' This feature communicates with the prediction model via API in real time to generate actionable insights.

VIII. EXPERIMENTAL EVALUATION

The IBM HR Analytics dataset consists of 1,470 employee records and 35 features. The natural imbalance in the dataset (churn rate ~16%) was addressed with SMOTE. XGBoost achieved an average ROC-AUC of 0.91 ± 0.02 in 5-fold cross-validation. 83.7% of departing employees were correctly predicted (recall); the false positive rate remained at 11.3%.

API response times were measured under 100 concurrent requests: the /employees list averaged 48 ms, single prediction 120 ms, and batch prediction (100 employees) 890 ms. The PostgreSQL GIN index accelerated JSONB query time on SHAP values by 12 times compared to the non-indexed state.

IX. DISCUSSION

The developed system successfully integrates a database-centric design with machine learning. The trigger-based audit logging mechanism provides a comprehensive traceability infrastructure that meets GDPR and similar compliance requirements. Role-based access control provides the necessary security layer for large-scale enterprise deployments.

The main limitations of the system are: the current dataset consists of only 1,470 records and needs retraining with larger, company-specific datasets; a static model infrastructure is used (real-time concept drift detection is planned).

X. CONCLUSION

In this study, a comprehensive employee churn prediction system was developed that brings together PostgreSQL 16's advanced features, the XGBoost machine learning model, and the SHAP explainability layer. The eight-table 3NF schema, trigger-based audit logging, views, and stored procedures demonstrate the system's maturity in terms of DBMS principles.

Experimental results prove that the XGBoost model demonstrates strong classification performance with 87.4% accuracy and a 0.91 ROC-AUC value. SHAP integration enhances the model's transparency, making it easier for HR teams to understand prediction rationales and act accordingly. The system has reached a software maturity ready for use in a real corporate environment.

REFERENCES

- [1] W. F. Cascio, "Managing Human Resources," 10th ed., McGraw-Hill Education, New York, 2018.
- [2] V. V. Saradhi ve G. K. Palshikar, "Employee churn prediction," *Expert Systems with Applications*, cilt 38, sayı 3, ss. 1999-2006, 2011.
- [3] F. Fallucchi, M. Coladangelo, R. Giuliano ve E. De Luca, "Predicting Employee Attrition Using Machine Learning Techniques," *Computers*, cilt 9, sayı 4, s. 86, 2020.
- [4] S. M. Lundberg ve S.-I. Lee, "A unified approach to interpreting model predictions," *Advances in Neural Information Processing Systems*, cilt 30, 2017.
- [5] T. Chen ve C. Guestrin, "XGBoost: A scalable tree boosting system," *Proc. 22nd ACM SIGKDD*, ss. 785-794, 2016.
- [6] S. Chawla, K. Bowyer, L. Hall ve W. Kegelmeyer, "SMOTE: Synthetic Minority Over-sampling Technique," *Journal of AI Research*, cilt 16, ss. 321-357, 2002.
- [7] IBM, "IBM HR Analytics Employee Attrition & Performance," Kaggle, 2017. [Cevrimici]. Erisim: <https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset>
- [8] S. Ramesh, "FastAPI: Modern, Fast Web Framework for Building APIs with Python," Packt Publishing, 2023.